

REPORTE DE ANÁLISIS DE AUDIO

Detección de Deepfakes mediante Inteligencia Artificial

Este reporte está diseñado para apoyar la interpretación del resultado entregado por el modelo: junto con el veredicto y su nivel de confianza, incorpora representaciones visuales de las regiones específicas del audio que el modelo identificó como más relevantes al momento de tomar su decisión.

RESULTADO DEL ANÁLISIS



AUDIO CLASIFICADO COMO

SOSPECHOSO

Confianza: 57.0%


Score del modelo

Probabilidad de voz REAL



57.0%

Probabilidad de DEEPFAKE



43.0%

21.06s

Duración

1

Bloques evaluados

8

Ventanas evaluadas

3/8

Ventanas FAKE

INFORMACIÓN DEL ARCHIVO

Archivo analizado	combinado_5.wav
Usuario	Kevin Soriano
Fecha de análisis	2026-07-19 02:30:37
Duración del audio	21.06 segundos
Modelo utilizado	GlowVox CNN-LSTM-Attention
Configuración	128 Mel-bands + Deltas temporales (16kHz), ventanas de 5s con 50% de solape

DETALLE DE BLOQUES EVALUADOS POR EL MODELO

BLOQUE	RANGO (mm:ss)	VENTANAS	SCORE PROM.	DESV. EST.	VEREDICTO	CONFIANZA
Bloque 1	00:00–00:20	8/8	0.4285	0.4422	INCONSISTENTE / MIXTO	62.5%

METODOLOGÍA DE EVALUACIÓN DEL MODELO

El modelo GlowVox divide el audio en bloques de hasta 52.5 segundos, cada uno compuesto por ventanas de 5 segundos con 50% de solape (hasta 20 ventanas por bloque). Cada ventana se transforma en un mel-espectrograma de 128 bandas (más sus derivadas de primer y segundo orden) y se evalúa de forma independiente con la red CNN-LSTM con atención, que produce un score entre 0 (voz real) y 1 (voz sintética) para esa ventana.

Un bloque se marca FAKE si la mayoría de sus ventanas superan el umbral de decisión (0.5); se marca REAL si la mayoría no lo superan; y se marca INCONSISTENTE / MIXTO si, aun sin ese predominio claro, la desviación estándar entre las ventanas del bloque es alta (≥ 0.15) — lo que indica que dentro de ese bloque hay ventanas con comportamiento marcadamente distinto entre sí, en lugar de un patrón homogéneo.

Dentro de cada ventana, antes de emitir el score, el modelo pasa la secuencia temporal por una capa de atención (Attention) que aprende a ponderar más unos frames que otros al construir el contexto final usado para clasificar. Ese peso de atención es real y se registra por ventana: cuando una ventana resulta decisiva para el veredicto de un bloque, el reporte marca con un círculo rojo el instante exacto donde ese peso se concentró — no es una estimación visual, es el mismo frame que el modelo más ponderó internamente.

El veredicto final del archivo completo sigue un criterio conservador: si CUALQUIER bloque resulta FAKE, todo el archivo se marca como DEEPFAKE, incluso si el resto del audio es real — porque un solo tramo sintético compromete la autenticidad del archivo completo. Si ningún bloque es FAKE pero al menos uno es INCONSISTENTE, el archivo se marca como SOSPECHOSO. Solo si todos los bloques son REAL, el archivo se marca como REAL.

¿POR QUÉ EL MODELO TOMÓ ESTA DECISIÓN?

El modelo no fue consistente entre los distintos tramos del audio (REAL global: 57.0% | DEEPFAKE global: 43.0%). Esto ocurre cuando al menos un bloque presenta alta variabilidad entre sus ventanas sin que ninguna ventana domine con claridad, lo que el sistema interpreta como evidencia de una posible mezcla de segmentos reales y sintéticos dentro del mismo audio, en lugar de forzar una clasificación binaria poco confiable.

El bloque 1 (00:00–00:20) fue el que generó la ambigüedad: 3/8 ventanas marcadas como sintéticas y una desviación estándar de 0.442 entre sus ventanas (por encima del umbral de variabilidad de 0.15 que el sistema usa para distinguir 'inconsistente' de un veredicto homogéneo). La ventana alrededor del segundo 00:12, con score 0.981, fue la que más se apartó del resto — el punto exacto donde conviene enfocar una revisión manual si se requiere confirmar el resultado. Dentro de esa ventana, la capa de atención del modelo concentró la mayor parte de su peso en el instante 00:14 (marcado con un círculo rojo en la forma de onda y en el mel-espectrograma), con un peso hasta 7.8 veces mayor que si hubiera atendido cada frame por igual.

ANÁLISIS VISUAL POR VENTANAS

Las siguientes representaciones muestran únicamente lo que el modelo procesó para tomar su decisión: la forma de onda con los bloques resaltados según su veredicto, el mel-espectrograma de 128 bandas (la representación de entrada real del modelo) y el score individual que el modelo asignó a cada ventana de 5 segundos evaluada. El círculo rojo señala, en cada bloque con veredicto FAKE o INCONSISTENTE, el instante exacto donde la capa de atención del modelo concentró más peso dentro de su ventana más decisiva.



CONCLUSIÓN Y RECOMENDACIONES

El análisis no fue concluyente (REAL: 57.0% | DEEPPFAKE: 43.0%). El/los bloque(s) 1 presentaron alta variabilidad entre sus ventanas sin que ninguna clase dominara con claridad (ver círculo rojo en la sección de análisis visual), lo que impide una clasificación definitiva. Se requiere análisis adicional, idealmente con foco en los bloques y ventanas señalados arriba.

- 1 Realizar análisis con herramientas forenses especializadas antes de tomar decisiones.
- 2 Solicitar una segunda opinión a un experto en análisis forense de audio.
- 3 No utilizar este resultado como evidencia en ningún contexto legal o formal.

■ **AVISO LEGAL** — Este reporte fue generado automáticamente por la plataforma GlowVox. Los resultados tienen carácter orientativo y NO constituyen prueba legal por sí solos. GlowVox no se responsabiliza por decisiones tomadas exclusivamente con base en este documento.